Segmentación Semántica de Caminos y Marcas Viales mediante Deep Learning

Juan Pablo Arteaga Patiño
A01665795
Instituto Tecnológico y de Estudios Superiores de Monterrey

Noviembre de 2026

Resumen

El resumen se redactará cuando concluya la experimentación y se cuente con resultados evaluados en el conjunto de prueba.

1. Introducción

La segmentación semántica asigna una categoría a cada píxel de una imagen y permite delimitar espacialmente las regiones de interés. En la percepción vial, distinguir la superficie del camino y las marcas de carril constituye una tarea relevante para sistemas de visión por computadora. Este trabajo explora dicha tarea mediante una red neuronal convolucional de tipo U-Net y el conjunto de imágenes viales de Makassar.

El proyecto comprende la preparación de las imágenes y sus anotaciones, la generación de una partición reproducible de entrenamiento, validación y prueba, y el desarrollo iterativo de una U-Net. A partir de un modelo preliminar se probaron cambios de arquitectura, resolución, regularización y métricas de optimización. La última iteración es la configuración más completa del proyecto hasta ahora; sin embargo, los resultados consignados corresponden al entrenamiento y no a una evaluación independiente en validación o prueba.

2. Conjunto de Datos y Preprocesamiento

2.1. Fuente y características del conjunto

Se utilizó el conjunto *Semantic Segmentation Makassar (IDN) Road*, consultado mediante DatasetNinja. Está compuesto por 374 imágenes capturadas en la ciudad de Makassar, Indonesia, con una cámara de tablero y resolución original de 2560×1600 píxeles. Las anotaciones semánticas a nivel de píxel comprenden tres clases: camino (`road`), línea continua (`lm_solid`) y línea discontinua (`lm_dashed`). El conjunto reporta 872 objetos anotados y no proporciona particiones predefinidas; por ello, la división de los datos se realizó como parte de este proyecto [1, 2].

La distribución por objetos informada por DatasetNinja se resume en el Cuadro 1. El área promedio por imagen muestra que las marcas de carril ocupan una fracción considerablemente menor que la superficie del camino. Estas estadísticas describen el conjunto según la ficha consultada; no deben confundirse con el conteo de píxeles de todas las máscaras procesadas en este trabajo.

Tabla 1: Estadísticas de clases reportadas para el conjunto Makassar Road [1].

Clase	Objetos	Área promedio por imagen
Camino (`road`)	374	17,85 %
Línea continua (`lm_solid`)	299	0,61 %
Línea discontinua (`lm_dashed`)	199	0,16 %

2.2. Proceso de ETL

El flujo de extracción, transformación y carga (ETL) leyó el proyecto y sus anotaciones JSON con la biblioteca Supervisely. Las anotaciones se almacenan como geometrías *Bitmap*; para cada objeto, se reconstruyó su máscara binaria y se colocó en la máscara completa usando las coordenadas de origen de la geometría. Las imágenes se convirtieron a RGB y las máscaras se guardaron en formato PNG, preservando los valores discretos de las etiquetas.

Se asignaron los índices 0, 1 y 2 a `road`, `lm_solid` y `lm_dashed`, respectivamente. Los píxeles sin una de esas etiquetas se inicializaron con el valor 255, destinado a representar fondo o regiones que deben ignorarse durante el aprendizaje. El proceso produjo 374 imágenes y 374 máscaras sin errores reportados, y verificó que las dimensiones de cada par coincidieran.

Como inspección preliminar, el cuaderno calculó la proporción de valores en una máscara de 1600×2560 píxeles: 14,37 % para camino, 0,41 % para línea continua, 0,29 % para línea discontinua y 84,94 % para el valor 255. Este cálculo corresponde a una máscara individual, no a un agregado de las 374 imágenes; por tanto, se presenta únicamente como verificación exploratoria y no como balance global de píxeles.

2.3. Partición de los datos

Al no existir una partición oficial, los 374 pares imagen-máscara se dividieron de forma aleatoria con semilla fija 67. Se asignaron 261 pares al entrenamiento (70 %), 56 a validación (15 %) y 57 a prueba (15 %). Se comprobó automáticamente la correspondencia de nombres entre imágenes y máscaras en cada partición. Las iteraciones descritas a continuación entrenaron con el conjunto de entrenamiento; no se documenta el uso de validación durante el ajuste ni se reportan métricas de prueba.

3. Metodología

3.1. Preprocesamiento y flujo de datos

Las imágenes se decodificaron como RGB, se normalizaron al intervalo $[0, 1]$ y se redimensionaron a 1280 píxeles de ancho por 720 de alto mediante interpolación bilineal. Las máscaras se ajustaron a la misma resolución con interpolación del vecino más cercano, para conservar los valores categóricos. El flujo de entrenamiento se implementó con `tf.data`, lotes de cuatro pares imagen-máscara, barajado y prelectura automática. La resolución de 1280×720 se adoptó después de una prueba de menor tamaño, pues permitió conservar más detalle espacial en las líneas viales. Aun así, no mantiene exactamente la relación de aspecto de las imágenes originales de 2560×1600; la deformación resultante debe tenerse en cuenta en la evaluación.

3.2. Arquitectura del modelo final

La arquitectura final es una U-Net implementada en TensorFlow/Keras, con entrada de forma $720 \times 1280 \times 3$. El codificador contiene cuatro bloques, con 16, 32, 64 y 128 filtros, respectivamente. Cada bloque aplica dos convoluciones 3×3 sin sesgo, cada una seguida de normalización por lotes y activación ReLU; entre los primeros tres bloques se reduce la resolución mediante *max pooling*. Esta configuración recupera dos convoluciones por bloque, después de que una versión más ligera con una convolución por bloque no distinguiera adecuadamente las marcas.

El decodificador tiene tres etapas de expansión con convoluciones transpuestas y conexiones de salto desde los bloques correspondientes del codificador. Cada etapa concatena los mapas de características alineados espacialmente y aplica una convolución para refinar la representación. La capa final es una convolución 1×1 con activación Softmax y cuatro canales. Se añadió aumento de datos mediante volteo horizontal, elegido para reflejar variaciones laterales de la escena sin invertir verticalmente la perspectiva de una cámara de tablero. No se aplicó volteo vertical.

3.3. Proceso de experimentación

La experimentación avanzó en cinco iteraciones. Las observaciones cualitativas y las métricas registradas en cada etapa orientaron los siguientes ajustes:

1. **Regularización inicial.** Se redujo el codificador a una convolución por bloque para disminuir el costo de cómputo, y se incorporaron normalización por lotes y volteo horizontal. En la inspección de predicciones se observó que el modelo favorecía la clase camino y omitía con frecuencia las líneas.

2. **Compensación del desbalance.** Se reemplazó la entropía cruzada convencional por una pérdida focal dispersa para dar más peso a predicciones difíciles y a las clases de menor presencia. También se probó parada temprana. La mejora de Mean IoU fue modesta, por lo que se planteó conservar mayor detalle espacial.

3. **Aumento de resolución.** Se cambió la entrada a 1280×720 y se retiró la parada temprana para permitir un entrenamiento más largo. La bitácora señala que mejoró la visibilidad de las líneas en las predicciones, aunque las métricas agregadas fueron inferiores a las de las primeras iteraciones.

4. **Recuperación de capacidad.** Se restauraron dos convoluciones por bloque y se extendió el máximo a 15 épocas, manteniendo la pérdida focal. La inspección cualitativa registró una detección más frecuente de las líneas, pero no una mejora clara al prolongar el entrenamiento más allá de diez épocas.

5. **Selección de métricas y parada.** Se sustituyó la exactitud por una métrica de *recall*, se mantuvo Mean IoU y se configuró *Early Stopping* con paciencia de tres épocas y restauración de los mejores pesos. La bitácora identifica esta configuración como la iteración final.

3.4. Configuración de entrenamiento

La última configuración utiliza el optimizador Adam con tasa de aprendizaje 10^{-4}, pérdida focal categórica dispersa con $\alpha = 0{,}25$ y $\gamma = 2$, y un tamaño de lote de cuatro. Se fijó un máximo de 15 épocas y se aplicó *Early Stopping* monitoreando la pérdida de entrenamiento, con paciencia de tres épocas y restauración de los mejores pesos. Según las notas de experimentación, el entrenamiento se detuvo en la época 9. La máscara codifica las clases de interés con índices 0, 1 y 2, y asigna 255 a los píxeles ignorados; en la pérdida focal personalizada, ese valor produce un vector objetivo nulo y no aporta pérdida. Sin embargo, el tratamiento de 255 en las métricas no está enmascarado explícitamente, y el cuarto canal de salida no corresponde a una clase objetivo definida. Estos detalles deben corregirse o verificarse antes de una evaluación concluyente.

Además, el volteo horizontal está implementado como una capa de aumento dentro del modelo y se aplica a la imagen de entrada. Para una tarea de segmentación, la misma transformación debe aplicarse de forma sincronizada a la máscara; el cuaderno no muestra esa transformación conjunta. La correspondencia entre imagen y etiqueta debe verificarse antes de atribuir el desempeño observado al modelo final.

4. Resultados

La bitácora del notebook informa que la quinta iteración alcanzó un *recall* aproximado de 92,54 % y un Mean IoU cercano a 0,45 al detenerse en la época 9. Estos valores se reportan como métricas de entrenamiento: la llamada a ajuste no incluye datos de validación y no se presenta una evaluación sobre el conjunto de prueba. Por tanto, no estiman el desempeño de generalización. Asimismo, el análisis cualitativo anotado indica que el modelo delimita la vía y sus marcas con mayor consistencia que las primeras versiones, pero todavía confunde las líneas continuas con las discontinuas.

El Cuadro 2 resume las métricas consignadas para las distintas etapas. Las comparaciones deben interpretarse con cautela: las primeras iteraciones reportan exactitud y Mean IoU, mientras que la última emplea *recall* y Mean IoU; no se documenta que las métricas se calcularan sobre un conjunto independiente ni se ofrecen IoU por clase.

Tabla 2: Evolución reportada durante la experimentación.

Iter.	Cambio principal	Métricas registradas; épocas
1	BN, volteo, bloque ligero	Exactitud: 92,40 %; mIoU: 0,4060; 10 épocas
2	Pérdida focal, parada temprana	Exactitud: 92,39 %; mIoU: 0,4186; detención en 5 (mejor: 2)
3	Entrada 1280×720	Exactitud: 91,22 %; mIoU: 0,3841; 10 épocas
4	Dos convoluciones por bloque	Sin métricas numéricas; máximo 15 épocas
5	*Recall*, mIoU, parada temprana	Recall: $\sim$92,54 %; mIoU: $\sim$0,45; detención en 9

La interpretación de estos resultados queda condicionada por aspectos pendientes del cuaderno: en la métrica no se excluye de manera explícita el valor 255, la salida tiene cuatro canales frente a tres clases semánticas anotadas y el volteo horizontal no se muestra aplicado conjuntamente a las máscaras. También falta conservar las salidas completas del entrenamiento final y presentar resultados desglosados por clase en validación y prueba. En consecuencia, los valores anteriores describen el avance experimental, pero no deben presentarse como una validación definitiva del segmentador.

5. Conclusiones

Las conclusiones se redactarán cuando se complete la evaluación del modelo y se analicen sus resultados en los conjuntos reservados.

Referencias

[1] DatasetNinja, “Semantic Segmentation Makassar (IDN) Road,” ficha del conjunto de datos. Consultado el 5 de noviembre de 2026. https://datasetninja.com/makassar-road.

[2] N. Azqalani, “Semantic Segmentation Makassar (IDN) Road,” conjunto de datos, 2022. https://www.kaggle.com/datasets/nublanazqalani/semantic-segmentation-makassaridn-road-datase