Segmentación Semántica de Caminos y Marcas Viales mediante Deep Learning

Juan Pablo Arteaga Patiño
A01665795
Instituto Tecnológico y de Estudios Superiores de Monterrey

Noviembre de 2026

Resumen

El resumen se redactará cuando concluya la experimentación y se cuente con resultados evaluados en el conjunto de prueba.

1. Introducción

La segmentación semántica asigna una categoría a cada píxel de una imagen y permite delimitar espacialmente las regiones de interés. En la percepción vial, distinguir la superficie del camino y las marcas de carril constituye una tarea relevante para sistemas de visión por computadora. Este trabajo explora dicha tarea mediante una red neuronal convolucional de tipo U-Net y el conjunto de imágenes viales de Makassar.

El proyecto se encuentra en una etapa preliminar: se completó la preparación de las imágenes y sus anotaciones, se generó una partición reproducible de entrenamiento, validación y prueba, y se implementó una primera versión de U-Net. El entrenamiento registrado en el cuaderno sirve como prueba inicial del flujo de modelado y aún no constituye una evaluación final. Antes de interpretar métricas será necesario resolver el tratamiento del fondo ignorado y evaluar el modelo con datos que no se hayan utilizado para entrenarlo.

2. Conjunto de Datos y Preprocesamiento

2.1. Fuente y características del conjunto

Se utilizó el conjunto *Semantic Segmentation Makassar (IDN) Road*, consultado mediante DatasetNinja. Está compuesto por 374 imágenes capturadas en la ciudad de Makassar, Indonesia, con una cámara de tablero y resolución original de 2560×1600 píxeles. Las anotaciones semánticas a nivel de píxel comprenden tres clases: camino (`road`), línea continua (`lm_solid`) y línea discontinua (`lm_dashed`). El conjunto reporta 872 objetos anotados y no proporciona particiones predefinidas; por ello, la división de los datos se realizó como parte de este proyecto [1, 2].

La distribución por objetos informada por DatasetNinja se resume en el Cuadro 1. El área promedio por imagen muestra que las marcas de carril ocupan una fracción considerablemente menor que la superficie del camino. Estas estadísticas describen el conjunto según la ficha consultada; no deben confundirse con el conteo de píxeles de todas las máscaras procesadas en este trabajo.

Tabla 1: Estadísticas de clases reportadas para el conjunto Makassar Road [1].

Clase	Objetos	Área promedio por imagen
Camino (`road`)	374	17,85 %
Línea continua (`lm_solid`)	299	0,61 %
Línea discontinua (`lm_dashed`)	199	0,16 %

2.2. Proceso de ETL

El flujo de extracción, transformación y carga (ETL) leyó el proyecto y sus anotaciones JSON con la biblioteca Supervisely. Las anotaciones se almacenan como geometrías *Bitmap*; para cada objeto, se reconstruyó su máscara binaria y se colocó en la máscara completa usando las coordenadas de origen de la geometría. Las imágenes se convirtieron a RGB y las máscaras se guardaron en formato PNG, preservando los valores discretos de las etiquetas.

Se asignaron los índices 0, 1 y 2 a `road`, `lm_solid` y `lm_dashed`, respectivamente. Los píxeles sin una de esas etiquetas se inicializaron con el valor 255, destinado a representar fondo o regiones que deben ignorarse durante el aprendizaje. El proceso produjo 374 imágenes y 374 máscaras sin errores reportados, y verificó que las dimensiones de cada par coincidieran.

Como inspección preliminar, el cuaderno calculó la proporción de valores en una máscara de 1600×2560 píxeles: 14,37 % para camino, 0,41 % para línea continua, 0,29 % para línea discontinua y 84,94 % para el valor 255. Este cálculo corresponde a una máscara individual, no a un agregado de las 374 imágenes; por tanto, se presenta únicamente como verificación exploratoria y no como balance global de píxeles.

2.3. Partición de los datos

Al no existir una partición oficial, los 374 pares imagen-máscara se dividieron de forma aleatoria con semilla fija 67. Se asignaron 261 pares al entrenamiento (70 %), 56 a validación (15 %) y 57 a prueba (15 %). Se comprobó automáticamente la correspondencia de nombres entre imágenes y máscaras en cada partición. La validación y la prueba se reservan para etapas posteriores; el cuaderno de modelado actual sólo construye el flujo de entrenamiento.

3. Metodología

3.1. Preprocesamiento y flujo de datos

Para el experimento inicial, las imágenes RGB se escalaron al intervalo $[0, 1]$ y se redimensionaron a 512 píxeles de ancho por 820 de alto mediante interpolación bilineal. Las máscaras se redimensionaron a la misma forma usando el vecino más cercano para conservar los identificadores enteros. Los datos se cargaron con la API `tf.data`, en lotes de cuatro imágenes, con barajado y prelectura automática.

La resolución implementada cambia la relación de aspecto de las imágenes originales (2560×1600 píxeles) al formato de entrada de 512×820 píxeles (ancho por alto). Esta transformación puede deformar la geometría de las marcas viales; deberá revisarse antes de los experimentos definitivos, considerando una resolución que preserve la proporción original o un recorte controlado.

3.2. Selección del modelo

Se eligió U-Net como arquitectura inicial por su estructura codificador-decodificador y sus conexiones de salto, que combinan características de distintas escalas para producir una predicción espacial por píxel. La implementación es propia y utiliza bloques convolucionales con 16, 32, 64 y 128 filtros en el codificador, seguidos por tres etapas de expansión con convoluciones transpuestas y concatenación de las activaciones correspondientes del codificador. Una convolución 1×1 con activación Softmax produce cuatro canales de salida. El modelo registrado contiene 482 084 parámetros entrenables.

La configuración se compiló con el optimizador Adam, tasa de aprendizaje 10^{-4}, entropía cruzada categórica dispersa y exactitud como métrica. Sin embargo, la codificación actual de etiquetas y la salida del modelo requieren una corrección antes de considerar válidos los resultados: las máscaras contienen los valores 0, 1, 2 y 255, mientras que la salida tiene cuatro canales y la función de pérdida no especifica que 255 se ignore. Por ello, debe definirse de manera consistente el conjunto de clases de salida y excluir explícitamente del cálculo de pérdida y métricas los píxeles ignorados.

3.3. Corrida preliminar

La corrida guardada en el cuaderno se limitó a tres épocas sobre el conjunto de entrenamiento. La exactitud y la pérdida reportadas por época se muestran en el Cuadro 2. Son métricas de entrenamiento de una ejecución exploratoria, no estimaciones de generalización: no se registraron resultados de validación o prueba. Además, por la inconsistencia de etiquetas descrita anteriormente y por la predominancia de píxeles de fondo/no anotados, estos valores no se interpretan como evidencia de desempeño satisfactorio.

Tabla 2: Métricas de entrenamiento registradas en la corrida inicial.

Época	Pérdida	Exactitud
1	0,3038	0,8155
2	0,2790	0,8226
3	0,2559	0,8852

4. Resultados

La evaluación cuantitativa final y el análisis cualitativo de predicciones quedan pendientes. Antes de reportarlos, se corregirá el tratamiento de la etiqueta 255 y se verificará la consistencia entre las clases objetivo y los canales de salida. También se revisará el redimensionamiento y se medirán métricas apropiadas para segmentación por clase —por ejemplo, intersección sobre unión— en los conjuntos de validación y prueba. La exactitud global por sí sola puede ocultar errores en las clases de marcas viales, debido a su reducida área relativa.

5. Conclusiones

Las conclusiones se redactarán cuando se complete la evaluación del modelo y se analicen sus resultados en los conjuntos reservados.

Referencias

[1] DatasetNinja, “Semantic Segmentation Makassar (IDN) Road,” ficha del conjunto de datos. Consultado el 5 de noviembre de 2026. `https://datasetninja.com/makassar-road`.

[2] N. Azqalani, “Semantic Segmentation Makassar (IDN) Road,” conjunto de datos, 2022. `https://www.kaggle.com/datasets/nublanazqalani/semantic-segmentation-makassaridn-road-datase`